

Integrasi Social Network Analysis dan Aspect-Based Sentiment Analysis dalam Memetakan Diskursus Pengesahan Perubahan RUU KUHAP di Platform X

Samuel Donovan Situngkir, Faiz Iqbal I'tishom, Naya Belva Kirana, Ario Rizky Muhammad,
Safina Aurora Andriani

Abstract

Pengesahan Rancangan Undang-Undang Kitab Undang-Undang Hukum Acara Pidana (RUU KUHAP) telah memicu dinamika opini publik yang kompleks di media sosial, di mana diskusi masyarakat sering kali bercampur dengan disinformasi dan bias interpretasi. Penelitian ini bertujuan untuk menganalisis respons masyarakat tersebut secara komprehensif dengan mengintegrasikan pendekatan Social Network Analysis (SNA) untuk memetakan interaksi dan Aspect-Based Sentiment Analysis (ABSA) untuk mendalami muatan opini pada platform X. Dengan memanfaatkan dataset sebanyak 1.924 tweet, penelitian ini melakukan eksperimen komparatif terhadap 125 kombinasi model algoritma serta analisis struktur jaringan komunikasi. Hasil SNA menunjukkan bahwa pola percakapan publik cenderung terfragmentasi dan bersifat satu arah, di mana interaksi lebih didominasi oleh penggunaan hashtag daripada dialog deliberatif antar pengguna, dengan siklus viralitas yang sangat singkat.

Dari sisi performa model sentimen, ditemukan bahwa pendekatan hibrida yang menggabungkan Support Vector Machine (SVM) kernel Polynomial dengan fitur embedding IndoTweet menghasilkan kinerja terbaik dengan F1-Score 0.773, mengungguli metode fine-tuning pada model Deep Learning untuk ukuran data moderat. Secara substantif, sentimen negatif mengerucut pada kekhawatiran terhadap perluasan wewenang aparat dan kriminalisasi, sedangkan sentimen positif didorong oleh dukungan terhadap keadilan restoratif dan upaya klarifikasi hoaks. Penelitian ini menyimpulkan bahwa diskursus RUU KUHAP lebih mencerminkan "perang narasi" yang terpolarisasi daripada diskusi kebijakan yang substansial.

Keywords: RUU KUHAP, Social Network Analysis, Aspect Based Sentiment Analysis ,Social Media Mining, Experimental Learning

Introduction

Perkembangan teknologi digital telah mengubah cara masyarakat berpartisipasi dalam diskusi publik. Media sosial tidak hanya menjadi sarana komunikasi, tetapi juga ruang deliberatif di mana opini terbentuk, dipertukarkan, dan dipengaruhi oleh interaksi antar pengguna. Platform X menempati posisi strategis sebagai ruang diskursus publik karena sifatnya yang real-time, terbuka, dan memungkinkan penyebaran informasi secara cepat. Menurut Veltri dan Atanasova (2017), media sosial berperan sebagai arena deliberatif yang mencerminkan dinamika opini masyarakat terhadap isu kebijakan melalui pola interaksi dan penyebaran narasi. [1]

Salah satu isu yang menimbulkan diskusi luas adalah Rancangan Undang-Undang Kitab Undang-Undang Hukum Acara Pidana (RUU KUHAP). Revisi terhadap regulasi hukum acara pidana membawa implikasi besar bagi sistem peradilan, penegakan hukum, serta perlindungan hak-hak warga negara. Permasalahan muncul karena publik seringkali kesulitan mengakses informasi komprehensif mengenai perubahan pasal, sementara opini yang beredar di media sosial dapat bercampur dengan disinformasi atau bias interpretasi. Akibatnya, dinamika opini masyarakat terkait RUU ini menjadi kompleks.

Oleh karena itu, penelitian ini memanfaatkan pendekatan *Social Network Analysis* (SNA) yang terbukti efektif dalam memetakan aktor kunci dan pola komunikasi di media sosial (Himelboim et al., 2017) [2] serta *Aspect-Based Sentiment Analysis* (ABSA) yang mampu mengidentifikasi sikap masyarakat secara lebih spesifik terhadap aspek tertentu dari suatu isu (Pontiki et al., 2016) [3]. Pendekatan terpadu ini diharapkan dapat memberikan pemahaman yang lebih komprehensif mengenai dinamika opini publik berbasis data dan menjadi kontribusi bagi kajian kebijakan, komunikasi digital, dan studi media sosial.

Related Works

Penelitian sebelumnya menunjukkan bahwa SNA efektif dalam mengidentifikasi pola interaksi dan aktor kunci dalam diskursus kebijakan, seperti pada isu TWK-KPK [4] dan kebijakan PSBB [5]. Di sisi lain, analisis sentimen, termasuk pendekatan ABSA, digunakan untuk memahami persepsi publik terhadap isu tertentu secara lebih spesifik [6][7]. Namun, sebagian besar studi masih menerapkan SNA dan analisis sentimen secara terpisah. Penelitian yang mengintegrasikan keduanya dalam konteks kebijakan publik, khususnya isu hukum nasional, masih terbatas. Oleh karena itu, penelitian ini mengisi celah tersebut dengan menggabungkan SNA dan ABSA dalam analisis diskursus RUU KUHAP.

Methods

Data dan Metodologi penelitian dijabarkan secara detail pada sub bab berikut, mulai dari penjelasan data yang digunakan (sumber dan penyiapan), hingga rincian metodologi komputasi yang diterapkan. Metodologi ini menjadi panduan kerja untuk analisis sentimen dan pemetaan jaringan sosial (SNA) pada data RUU KUHAP.

1. Material

Data yang digunakan dalam penelitian merupakan data sekunder berupa *tweet* yang dikumpulkan melalui *platform* media sosial Twitter (X) dengan fokus pada topik Rancangan Undang-Undang Kitab Undang-Undang Hukum Acara Pidana (RUU KUHAP). Pengambilan data awal mendapatkan sebanyak 2000 *tweet*, kemudian data melalui tahap pembersihan (*Data Cleaning*), di mana 2 data *noise* dan 74 data duplikat dihilangkan. Dengan demikian, jumlah total data akhir yang digunakan untuk pemodelan adalah 1924 *tweet*. Variabel utama yang menjadi target klasifikasi sentimen dirangkum dalam tabel berikut:

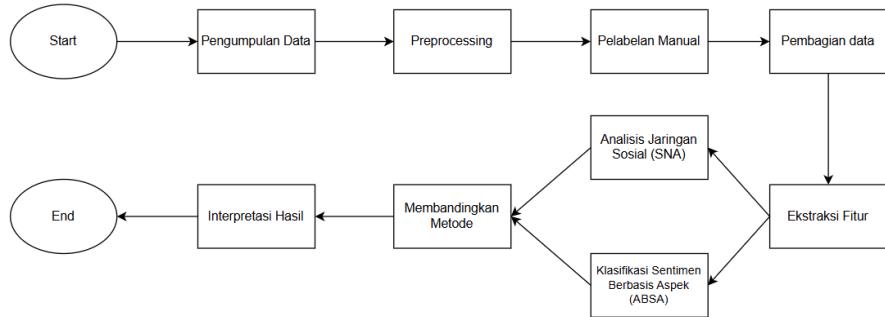
Tabel 1. Variabel Penelitian

Variabel	Keterangan
Sentimen	Klasifikasi emosi atau pandangan terhadap RUU KUHAP.
Positif	Teks yang menunjukkan dukungan, persetujuan, atau pandangan baik terhadap RUU KUHAP.
Negatif	Teks yang menunjukkan penolakan, kritik, atau pandangan buruk terhadap RUU KUHAP.
Netral	Teks yang berisi fakta, informasi, atau pandangan yang tidak menunjukkan bias positif maupun negatif.

2. Methodology

Penelitian ini menerapkan dua pendekatan analitik yang berbeda namun saling melengkapi, yaitu *Bert Embedding* untuk *Aspect Based Sentiment Analysis* (ABSA) dan *Social Network Analysis* (SNA) untuk memetakan dinamika interaksi sosial di Platform X. Langkah-langkah analisis yang diterapkan dalam penelitian ini adalah sebagai berikut:

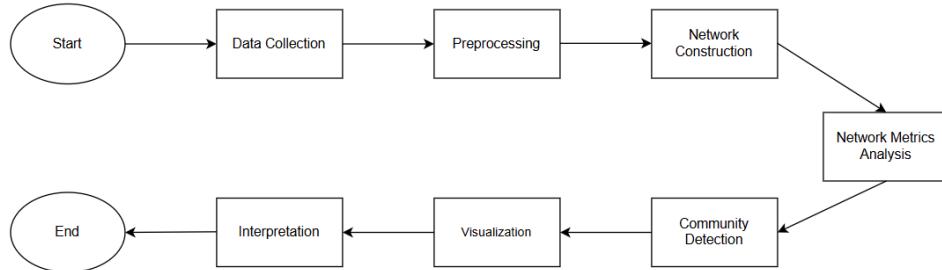
2.1 Alur Penelitian



Gambar 1. Flowchart tahapan analisis

Gambar 1 menjelaskan alur penelitian terintegrasi yang menggabungkan Analisis Sentimen Berbasis Aspek (ABSA) dan Analisis Jaringan Sosial (SNA) terhadap diskursus RUU KUHAP di Platform X. Proses dimulai dari Pengumpulan Data *tweet* menggunakan kata kunci yang relevan, diikuti dengan Pra-pemrosesan Data yang mencakup *cleaning*, *tokenizing*, dan *normalizing*. Setelah itu, data sebanyak 1.924 *tweet* melalui Pelabelan Sentimen Manual dengan nilai negatif (0), netral (1), dan positif (2) untuk menetapkan *ground truth*. Kemudian, data dibagi (*stratified*) dan dilakukan Ekstraksi Fitur menggunakan *Embedding* BERT (IndoBERT dan IndoTweet). Pemodelan melibatkan tiga pendekatan: *Machine Learning* Klasik (28 algoritma), *Deep Learning*, dan *Transformer* (*fine-tuning*). Model terbaik (SVM Kernel Polynomial + IndoTweet) dipilih untuk Analisis Lanjutan, yang mencakup Identifikasi Aspek (*Clustering*) dan Analisis Kesalahan. Secara paralel, data interaksi diproses untuk Analisis Jaringan Sosial (SNA). Tahap akhir adalah Sintesis Hasil ABSA dan SNA untuk menyusun interpretasi komprehensif mengenai dinamika opini publik RUU KUHAP.

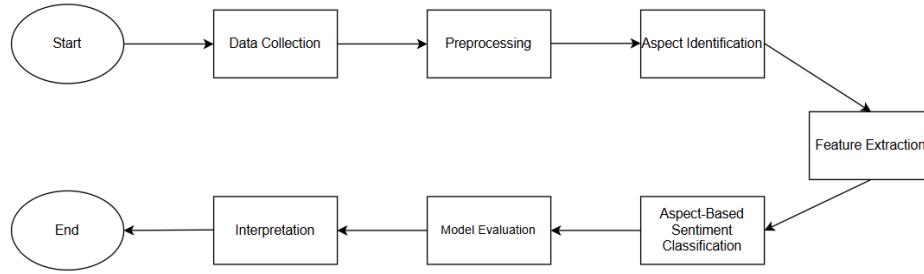
2.2 Alur Social Network Analysis



Gambar 2. Flowchart Social Network Analysis

Gambar 2.2 menunjukkan alur lebih detail untuk proses Analisis Jejaring Sosial (SNA) yang berjalan paralel dalam penelitian. Proses dimulai dari Pemuatan Dataset interaksi, kemudian dilakukan Pra-pemrosesan Data khusus SNA untuk membersihkan dan menyiapkan data *node* dan *edge* sebelum konstruksi jaringan. Selanjutnya, dilakukan Perhitungan Centrality Measures (termasuk *Degree*, *Betweenness*, *Eigenvector*, dan *PageRank*) untuk mengidentifikasi peran dan pengaruh penting setiap pengguna dalam jaringan. Setelah itu, Visualisasi Graf Jaringan dilakukan bersama dengan Deteksi Komunitas menggunakan Algoritma Louvain untuk memetakan struktur interaksi dan mengidentifikasi kelompok diskusi. Tahap akhir melibatkan Analisis Sentimen per Komunitas dan penghitungan Composite Score Influencer untuk merangkum temuan utama SNA sebelum disintesis dengan hasil ABSA.

2.3 Alur Aspect Based Sentiment Analysis



Gambar 3. Flowchart Aspect Based Sentiment Analysis

Gambar 3 (Flowchart Aspect-Based Sentiment Analysis) menjelaskan secara rinci alur yang mengarah pada penentuan model sentimen terbaik. Proses dimulai setelah Pelabelan Data manual dan Pembagian Data (Train & Test Set) selesai. Tahap krusial berikutnya adalah Ekstraksi Fitur yang membandingkan lima metode representasi teks, dengan fokus utama pada *Embedding* kontekstual (IndoBERT dan IndoTweet). Vektor hasil fitur ini kemudian digunakan dalam dua jalur pemodelan: Pemodelan Klasik (*Screening*) terhadap 28 algoritma yang dilanjutkan dengan Hyperparameter Tuning menggunakan *GridSearchCV* pada 5 model teratas (termasuk SVM, XGBoost, dan LightGBM), serta Pemodelan Transformer melalui *Fine-Tuning* IndoBERT dan IndoTweet. Kinerja semua model dievaluasi menggunakan metrik F1-Score pada data uji. Hasil perbandingan ini menentukan Model Sentimen Terbaik yang akan digunakan untuk Identifikasi Aspek (*Clustering*) dan Analisis Kesalahan (sarkasme, dll.), sebelum hasil akhir ABSA disiapkan untuk interpretasi.

2.4 Data Acquisition

Pengumpulan data dilakukan melalui proses *scraping* pada media sosial X menggunakan kata kunci utama yang berkaitan dengan RUU KUHAP. Proses ini menghasilkan total 1.924 *tweet*. Data yang diambil mencakup teks (*full_text*), ID pengguna, dan metadata interaksi (*reply*, *mention*, *retweet*) yang krusial untuk analisis jaringan.

2.5 Data Preprocessing

Tahapan ini dilakukan untuk membersihkan dan menstandarisasi data teks, mengubahnya dari teks mentah (*raw text*) menjadi format siap proses oleh model.

Proses ini meliputi pembersihan teks, normalisasi kata, dan tokenisasi:

1. Text Cleaning: Dilakukan *lowercasing*, penghapusan URL, *mention*, *hashtag*, tanda baca, dan karakter non-alfabet. Hasilnya disimpan pada kolom *clean_text*.
2. Ultimate Preprocessing: Proses ini bertujuan menyeragamkan variasi kata dan menjaga makna inti teks.
 - a. Normalisasi Kata: Dilakukan normalisasi kata berbasis kamus (misalnya: 'gak' menjadi 'tidak', 'yg' menjadi 'yang').
 - b. Stopword Removal: Penghapusan kata-kata umum yang tidak informatif (seperti konjungsi dan pronomina), dengan pengecualian kata negasi (tidak, bukan) untuk menjaga polaritas sentimen.
 - c. Stemming: Penerapan *stemming* Sastrawi untuk mereduksi kata menjadi kata dasar (misalnya: 'menganalisis' menjadi 'analisis').
 - d. Reduksi Karakter: Reduksi perulangan karakter yang berlebihan (misalnya: 'baaaaik' menjadi 'baik').
3. Tokenisasi: Memecah teks menjadi unit-unit kata.

2.6 Data Labeling dan Pembagian Data

2.6.1 Pelabelan Data Manual

Seluruh 1.924 *tweet* diberi label sentimen (Negatif/0, Netral/1, Positif/2) secara manual oleh 3 orang validator. Label final ditentukan melalui sistem *vote* mayoritas untuk memastikan *ground truth* yang objektif.

2.6.2 Pembagian Data

Dataset kemudian dibagi secara stratified menjadi 80% Set Pelatihan (Train Set) dan 20% Set Pengujian (Test Set). Skema *stratified* menjamin distribusi jumlah label sentimen (kelas 0, 1, 2) dalam *train set* dan *test set* tetap proporsional.

2.7 Social Network Analysis

2.7.1 Network Construction

1. User Mention Network: Jaringan dibangun menggunakan directed graph (graf berarah), di mana *Nodes* adalah pengguna, dan *Edges* adalah interaksi (*mention*, *reply*, *retweet*).
2. Hashtag Co-Occurrence Network: Jaringan ini memetakan keterkaitan topik RUU KUHAP, di mana *Nodes* adalah *hashtag* yang muncul, dan *Edges* adalah kemunculan dua *hashtag* bersamaan dalam satu *tweet*.
3. Filtering Network: Jaringan disaring dengan memangkas *node* atau *edge* yang memiliki kontribusi/interaksi sangat minim (ambang batas ditentukan secara heuristik) untuk memperjelas struktur inti.

2.7.2 Centrality Measures dan Community Detection

1. Pengukuran Centrality:
 - a. Degree Centrality: Mengidentifikasi akun yang memiliki koneksi langsung terbanyak (popularitas).
 - b. Betweenness Centrality: Mengidentifikasi akun yang berperan sebagai jembatan penghubung antar kelompok.
 - c. Eigenvector Centrality: Menilai pengaruh sebuah akun berdasarkan kualitas koneksinya dengan aktor berpengaruh lain.
 - d. PageRank: Digunakan untuk mengukur pentingnya sebuah *node* dalam jaringan.
2. Community Detection: Algoritma Louvain diterapkan pada *Mention Network* untuk mengelompokkan akun ke dalam komunitas berdasarkan kerapatan interaksi.
3. Community Sentiment: Sentimen (*Positif/Netral/Negatif*) yang dominan dihitung dan diidentifikasi di dalam setiap komunitas yang terbentuk (hasil rata-rata sentimen *node*).
4. Composite Score Influencer: Dirumuskan skor tunggal hasil agregasi metrik sentralitas untuk menentukan peringkat aktor paling berpengaruh (*Key Opinion Leader*).
5. Sentiment Heatmap antar Komunitas: Memvisualisasikan distribusi sentimen antar komunitas untuk mengidentifikasi pola hubungan emosional.

2.8 Aspect-Based Sentiment Analysis

ABSA digunakan untuk klasifikasi sentimen pada *tweet* dan identifikasi aspek.

2.8.1 Feature Extraction

Teks hasil *preprocessing* diubah menjadi vektor numerik menggunakan lima metode ekstraksi fitur untuk perbandingan komprehensif:

1. Bag of Words (BoW) & TF-IDF: Metode statis, digunakan sebagai *baseline* (batas 5.000 fitur).
2. Word2Vec: Menghasilkan *dense vector* semantik (dimensi 100).
3. IndoBERT Embeddings: Menghasilkan *embedding* kontekstual (dimensi 768) dari model indobenchmark/indobert-base-p1 (*last hidden state*).
4. IndoTweet Embeddings: Menghasilkan *embedding* kontekstual (dimensi 768) dari model indolem/indobertweet-base-uncased, yang dilatih khusus pada data Twitter.

2.8.2 Desain Eksperimen dan Screening

Eksperimen dilakukan dengan membagi dataset menjadi data latih (train set) dan data uji (test set) dengan rasio 80:20 menggunakan metode stratified sampling. Hal ini dilakukan untuk menjaga proporsi distribusi kelas sentimen pada kedua *subset* data agar representatif.

Algoritma yang diuji mencakup berbagai keluarga model dalam fase *screening* awal untuk mengidentifikasi kombinasi algoritma dan fitur terbaik. Keluarga model yang diuji antara lain:

1. Linear Models: Logistic Regression, Ridge Classifier, SGD Classifier, Passive Aggressive.
2. Support Vector Machines (SVM): Linear SVC, SVC (Kernel RBF, Poly), Nu-SVC, Perceptron.
3. Naive Bayes: Multinomial, Bernoulli, Complement, Gaussian NB.
4. Tree-Based & Ensemble: Decision Tree, Random Forest, Extra Trees, AdaBoost, Gradient Boosting.
5. Advanced Ensemble (Boosting): XGBoost, LightGBM, CatBoost.
6. Neural Networks: MLP Classifier (Shallow & Deep).
7. Distance-Based: K-Nearest Neighbors (KNN), Nearest Centroid.

Screening: Penelitian ini melakukan Screening awal terhadap 28 algoritma klasifikasi berbeda yang dikombinasikan dengan berbagai fitur (5 fitur x 28 model) untuk mengidentifikasi kandidat model terbaik.

2.8.3 Hyperparameter Tuning dan Fine-Tuning

Optimasi kinerja model klasifikasi dilakukan pada 5 model teratas dari hasil *screening* awal (*Machine Learning* Klasik), yaitu Support Vector Machine (SVM), XGBoost, dan LightGBM. Optimasi ini dilakukan melalui proses Hyperparameter Tuning yang sistematis menggunakan GridSearchCV dengan skema 5-Fold Cross-Validation dan metrik F1-Macro. Sementara itu, model *Transformer* (IndoBERT dan IndoTweet) dioptimasi melalui proses *fine-tuning* langsung pada data latih.

2.8.3 Penentuan Model Terbaik

Model sentimen terbaik dipilih berdasarkan F1-Score tertinggi pada data uji. Konfigurasi yang terpilih adalah pendekatan hibrida yang menggabungkan: Support Vector Machine (SVM) Kernel Polynomial dengan *Embedding* IndoTweet. Untuk justifikasi model terbaiknya pemilihan ini didasarkan pada F1-Score optimal dan tingginya robustness SVM, terutama kemampuannya untuk meminimalkan *False Optimism* (klasifikasi sentimen *Negatif* menjadi *Positif*) yang sangat penting dalam analisis isu sensitif.

2.8.4 Identifikasi Aspek (Clustering)

Aspek RUU KUHAP diidentifikasi melalui pendekatan unsupervised learning menggunakan algoritma *Clustering* yang diterapkan langsung pada vektor *embedding* BERT (IndoTweet/IndoBERT), menghasilkan klaster-klaster topik spesifik.

2.8.5 Analisis Kesalahan

Analisis Kesalahan dengan melakukan analisis mendalam terhadap matriks kebingungan (*confusion matrix*) dari model terbaik untuk mengidentifikasi pola kesalahan sistematis (misalnya: kesalahan akibat sarkasme, *false optimism*, *ambiguity error*).

2.9 Metrik Evaluasi Model

Kinerja model dievaluasi menggunakan F1-Macro dan Akurasi. F1-Macro dipilih sebagai metrik utama karena sensitif terhadap *class imbalance* dan memberikan penilaian yang lebih adil pada data sentimen yang tidak seimbang.

Result

3.1 Descriptive Analysis

3.1.1 Descriptive Statistic

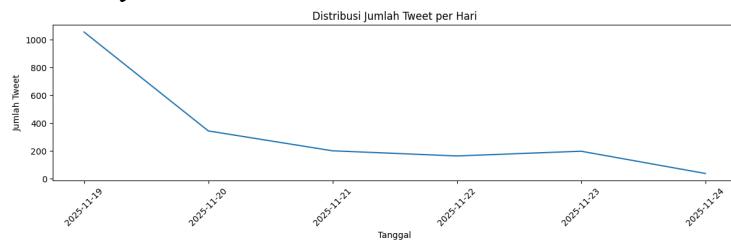
Statistika deskriptif bertujuan untuk memberikan gambaran umum mengenai distribusi sentimen publik, intensitas percakapan, serta mengidentifikasi aktor-aktor kunci yang memicu interaksi awal.

Tabel 2. Descriptive Statistic

Variabel	count	mean	std	min	25%	50%	75%	max
conversation_id_str	2,0e+03	1,9e+18	5,7e+14	1,9e+18	1,9e+18	1,9e+18	1,9e+18	1,9e+18
favorite_count	2000	15,916	268,132	0	0	0	1	8669
id_str	2,0e+03	1,9e+18	5,4e+14	1,9e+18	1,8e+18	1,9e+18	1,9e+18	1,9e+18
location	0	NaN						
quote_count	2000	0,37	8,772	0	0	0	0	351
reply_count	2000	0,672	4,0477	0	0	0	1	145
retweet_count	2000	4,6145	69,690	0	0	0	0	2563
user_id_str	2,0e+03	1,1e+18	7,6e+17	1,5e+07	2,8e+09	1,3e+18	1,7e+18	1,9e+18
username	0	NaN						

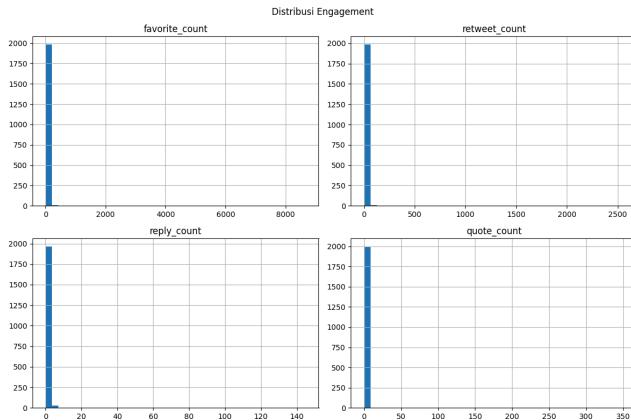
Tabel merangkum statistik dari 2.000 postingan Twitter/X. Sebagian besar interaksi likes, retweet, balasan, dan kutipan memiliki median 0, yang berarti mayoritas postingan tidak mendapat respons. Namun, nilai rata-rata menjadi tinggi karena adanya beberapa postingan yang sangat viral dengan jumlah interaksi ekstrem. Sementara itu, kolom *location* dan *username* tidak memberikan informasi numerik yang berarti, sehingga tidak relevan untuk interpretasi statistik.

3.1.2 Exploratory Data Analysis



Gambar 4. Distribusi Jumlah Tweet

Gambar menunjukkan bahwa topik RUU KUHAP merupakan isu yang viral secara mendadak namun berumur pendek. Grafik tren waktu memperlihatkan bahwa antusiasme tidak bertahan lama, perhatian publik naik pada tanggal 19 November 2025 dengan lebih dari 1.000 tweet, tetapi turun drastis dan terus mereda hingga hampir hilang pada tanggal 24 November 2025. Pola ini menandakan reaksi publik yang spontan dan keras terhadap suatu peristiwa, tetapi tidak diikuti dengan diskusi jangka panjang.

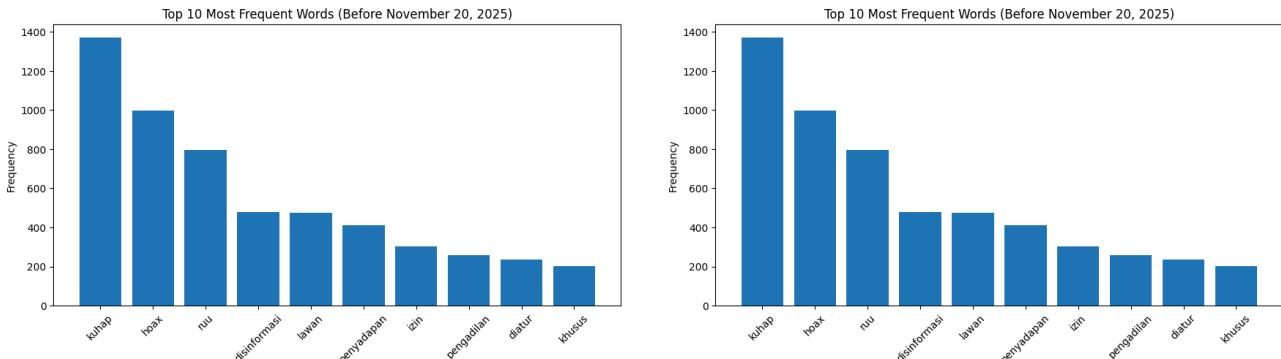


Gambar 5. Distribusi Engagement

Gambar di atas menunjukkan empat grafik histogram yang menggambarkan sebaran interaksi (engagement) media sosial, yaitu jumlah *favorite*, *retweet*, *reply*, dan *quote*. Keempat grafik memiliki pola yang sangat identik, yaitu distribusi yang sangat timpang ke kanan (highly right-skewed). Artinya, mayoritas besar data berkumpul di angka nol atau angka yang sangat kecil. Hal ini menunjukkan bahwa sebagian besar postingan dalam dataset ini mendapatkan sedikit sekali atau bahkan tidak ada interaksi sama sekali. Sebaliknya, hanya segelintir postingan kecil (yang hampir tidak terlihat di grafik karena jumlahnya sedikit) yang memiliki angka interaksi tinggi atau viral. Ini adalah pola yang sangat umum dalam data media sosial.



Gambar 6. Wordcloud dan Most Frequent Word



Gambar 7. Most Frequent Word

Gambar memperlihatkan pergeseran topik pembicaraan publik yang terjadi di tengah pola interaksi yang sangat timpang. Meskipun sebagian besar postingan mendapat sedikit sekali respons dan hanya segelintir yang viral, fokus percakapan berubah total setelah tanggal 20 November. Awalnya, orang-orang sibuk berdebat soal "hoax" dan seruan "lawan", tetapi kemudian berubah menjadi diskusi serius membahas "pasal", "hukum", dan "DPR". Ini menunjukkan bahwa publik telah beralih dari sekadar perang narasi di media sosial menjadi menghadapi kenyataan hukum yang sudah resmi berlaku.

3.1.3 Topic Modelling

Berdasarkan hasil pemodelan topik (topic modelling) yang membagi data ke dalam lima klaster utama, ditemukan bahwa percakapan publik memiliki struktur tematik yang beragam. Topik 1 dan Topik 5 merepresentasikan diskusi substantif terkait aspek legalitas dan kelembagaan, yang ditandai dengan munculnya kata kunci seperti "pengesahan", "transparan", "keadilan", "DPR", dan "komisi III". Di sisi lain, Topik 4 menangkap narasi ketakutan dan resistensi publik dengan dominasi kata kunci "disinformasi", "hoax", "lawan", dan "penyadapan". Sementara itu, Topik 2 mencerminkan lapisan percakapan yang lebih informal atau komentar umum masyarakat mengenai status RUU, yang ditandai dengan banyaknya penggunaan kata-kata sehari-hari seperti "aja", "udah", dan "bisa". Terakhir, analisis ini juga mendeteksi adanya noise pada Topik 3, yang berisi kata-kata promosi komersial dan spam (seperti "shopee", "promo", "referral") yang tidak relevan dengan isu RUU KUHP, mengindikasikan bahwa ekosistem percakapan turut disusupi oleh aktivitas bot atau iklan otomatis.

3.2 Social Network Analysis

Analisis jaringan sosial dilakukan menggunakan data tweet yang telah melalui tahap pra pemrosesan dan pelabelan sentimen, sehingga jaringan yang dibangun merepresentasikan interaksi dan topik yang relevan dengan diskursus RUU KUHAP.

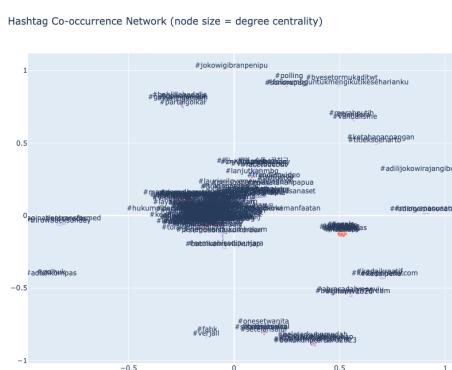
3.2.1 Network Overview

Setiap pasangan mention dicatat sebagai *edge* pada *undirected graph*, menghasilkan jaringan dengan 293 *node* dan 1.826 *edge*. Banyaknya *node* menunjukkan keberagaman aktor, sedangkan *edge* mencerminkan interaksi padat.

3.2.2 User Mention Network

Struktur jaringan menunjukkan ketimpangan ekstrem dengan 452 node namun hanya 5 edge, di mana hanya satu akun ("_") yang memiliki in-degree (5 mention). Minimnya relasi ini mengindikasikan diskursus RUU KUHAP bersifat terfragmentasi dan satu arah, di mana pengguna lebih fokus menyuarakan opini tanpa dialog, sehingga dinamika publik lebih didominasi oleh penggunaan hashtag daripada interaksi antar pengguna.

3.2.3 Hashtag Co-Occurrence Network



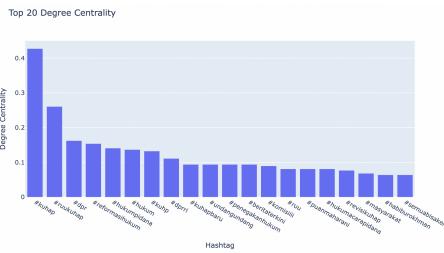
Gambar 8. Hashtag Co-Occurrence Network

Gambar menunjukkan adanya area yang lebih padat, menandakan kelompok isu yang saling terhubung kuat. Node berukuran besar seperti #kuhap, #ruukuhap, dan #dpr memiliki degree tinggi dan berada di pusat klaster, sehingga berperan sebagai pengikat utama dalam wacana publik. Sejumlah kelompok kecil di bagian luar jaringan merepresentasikan topik yang lebih spesifik atau kontekstual, meskipun relevan, tidak membentuk hubungan sekuat klaster utama.

3.2.4 Centrality Analysis

Untuk mengidentifikasi hashtag yang memiliki pengaruh paling besar dalam jaringan ko-occurrence, dilakukan analisis centrality menggunakan tiga metrik utama, yaitu degree, betweenness, dan eigenvector centrality.

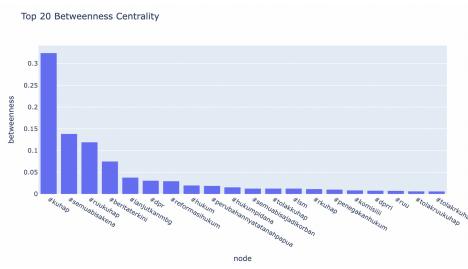
3.2.4.1 Degree Centrality



Gambar 9. Visualisasi Top 20 Degree Centrality

Grafik menunjukkan bahwa #kuhap dan #ruukuhap merupakan hashtag paling sentral dalam jaringan, diikuti oleh #dpr dan #reformasihukum, yang menegaskan bahwa diskursus publik terfokus pada isu utama revisi KUHAP dan proses kelembagaannya

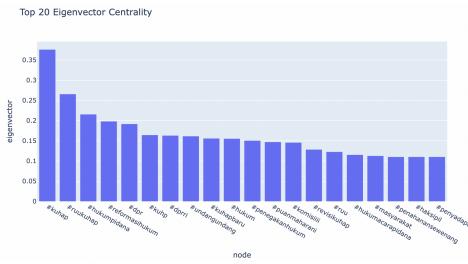
3.2.4.2 Betweenness Centrality



Gambar 10. Visualisasi Top 20 Betweenness Centrality

Grafik ini menunjukkan bahwa #kuhap memiliki nilai *betweenness centrality* tertinggi, menandakan perannya sebagai penghubung utama antar bagian jaringan percakapan. Hashtag lain seperti #semuabisakena dan #ruukuhap juga memiliki peran penghubung yang relatif penting, meskipun dengan nilai yang lebih rendah. Temuan ini mengindikasikan bahwa alur informasi dalam diskursus RUU KUHAP sangat bergantung pada sejumlah kecil hashtag kunci yang menjembatani berbagai topik dan kelompok percakapan.

3.2.4.3 Eigenvector Centrality

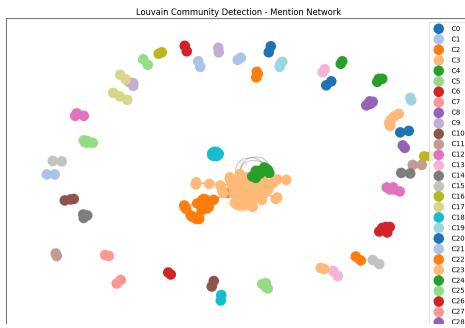


Gambar 11. Visualisasi Top 20 Eigenvector Centrality

Grafik *eigenvector centrality* menunjukkan bahwa #kuhap dan #ruukuhap memiliki pengaruh paling kuat dalam jaringan karena terhubung dengan hashtag lain yang juga bersifat sentral. Hashtag seperti #hukumpidana, #reformasihukum, dan #dpr turut menempati posisi penting, menandakan kedekatannya dengan simpul-simpul berpengaruh lainnya. Hasil ini mengindikasikan bahwa struktur percakapan RUU KUHAP tidak hanya terpusat pada hashtag yang sering muncul, tetapi juga pada hashtag yang berada dalam inti jaringan diskursus.

3.2.5 Community Detection

3.2.5.1 Louvain Community Detection – Mention Network



Gambar 12. Visualisasi Louvain Community Detection – Mention Network

Community detection menggunakan algoritma Louvain mengidentifikasi 47 komunitas dalam *mention network*. Visualisasi menunjukkan struktur jaringan yang terfragmentasi, dengan banyak komunitas kecil di tepi jaringan dan satu komunitas besar di pusat yang memiliki keterhubungan tinggi. Diskursus lintas komunitas terutama dipusatkan pada akun politik dan institusi, seperti prabowo, DPR_RI, dan puanmaharani_ri. Analisis sentimen per komunitas memperlihatkan dominasi sentimen netral, dengan variasi sentimen positif dan negatif pada komunitas tertentu, yang mencerminkan perbedaan dinamika opini dalam diskursus RUU KUHAP.

3.2.5.2 Centrality Measures pada Mention Network

Hasilnya menunjukkan bahwa akun politik dan institusi menempati posisi penting. Degree centrality tinggi menunjukkan banyak koneksi langsung, betweenness centrality menandai peran sebagai penghubung antar kelompok, dan eigenvector serta PageRank mengonfirmasi kedekatan dengan aktor berpengaruh lainnya. Akun seperti *prabowo*, *puanmaharani_ri*, *DPR_RI*, serta organisasi seperti YLBHI menjadi pusat percakapan, menandakan diskursus KUHAP berfokus pada figur politik dan lembaga kunci lintas komunitas.

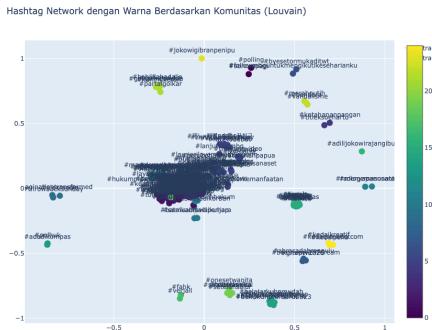
3.2.6 Community Sentiment Analysis

Analisis sentimen per komunitas menunjukkan sebagian besar kelompok memiliki sentimen netral, sesuai dengan fokus percakapan yang informatif. Beberapa komunitas, seperti 0, 8, dan 12, menunjukkan kecenderungan positif (rata-rata 0,15–0,2), menandakan narasi suportif atau optimistis, sementara komunitas 23 dan 46 cenderung negatif dengan nilai rata-rata di bawah nol,

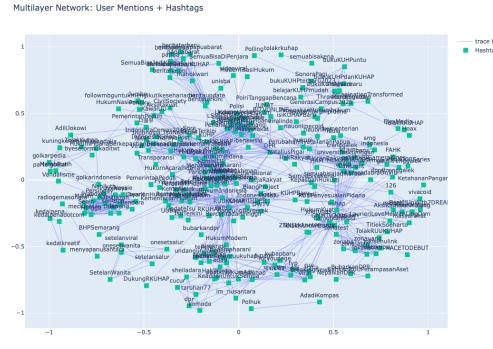
mencerminkan ekspresi kritik. Perbedaan ini menggambarkan pembentukan opini dan emosi kolektif dalam diskursus RUU KUHAP.

3.2.7 Top Influencers Berdasarkan Composite Score

Untuk memperoleh gambaran yang lebih menyeluruh mengenai pengaruh setiap hashtag, seluruh nilai sentralitas dinormalisasi dan digabungkan ke dalam satu metrik *composite score* dengan bobot 40% untuk degree, 30% untuk betweenness, dan 30% untuk eigenvector centrality.



Gambar 13. Visualisasi Hashtag Network



Gambar 14. Visualisasi Multilayer Network

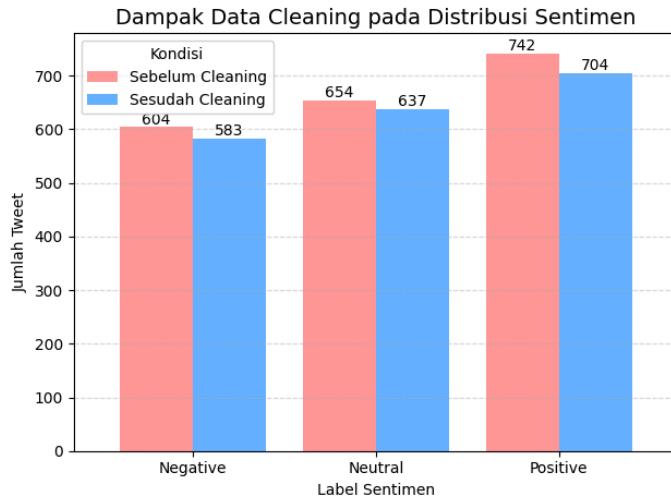
Hasil penggabungan menunjukkan bahwa hashtag #kuhaph menempati posisi tertinggi, diikuti #ruukuhap, #dpr, #reformasihukum, dan #hukumpidana. Kelima hashtag muncul sebagai simpul paling dominan karena selain sering digunakan, tetapi juga memiliki keterhubungan kuat dengan berbagai topik lain dalam jaringan. Temuan ini menegaskan bahwa isu revisi KUHAP berfungsi sebagai pusat wacana yang menghubungkan beragam tema dalam percakapan publik.

3.2.8 Multilayer Network: User Mentions + Hashtags

Pada tahap akhir, analisis *multilayer* dilakukan untuk menggabungkan dua jaringan penting yaitu *user mention network* dan *hashtag network*. Visualisasi multilayer berikut memberikan gambaran struktur interaksi pengguna dan topik secara simultan. Struktur multilayer memperlihatkan bahwa interaksi pengguna dengan *hashtag* terhubung cukup erat, terutama pada simpul yang berkaitan dengan topik sentral seperti KUHAP dan isu legislasi. Pengguna tertentu tampak berperan sebagai penghubung antara berbagai *hashtag*, yang memperkuat penyebarluasan informasi melalui mekanisme *mention* dan penggunaan *hashtag* secara bersamaan. Kehadiran klaster terpisah pada jaringan juga menunjukkan adanya kelompok diskusi yang lebih spesifik yang beroperasi dengan fokus topik yang berbeda.

3.3 Sentiment Analysis

3.3.1 Distribusi Sentimen Keseluruhan



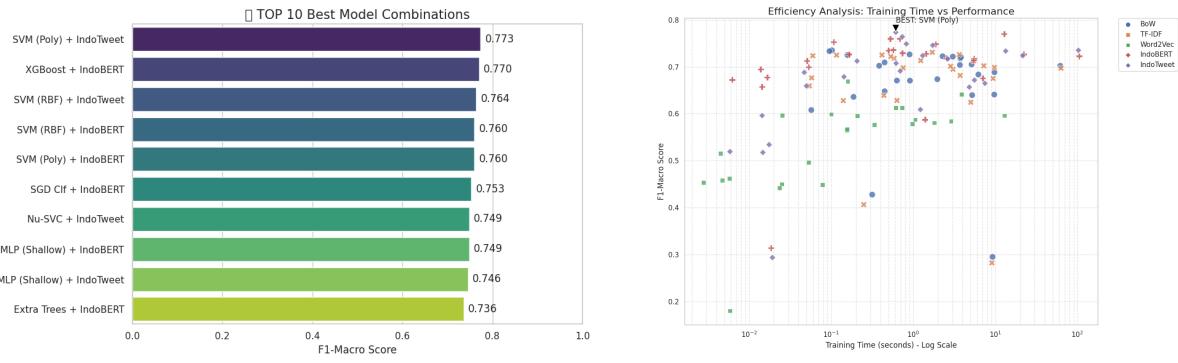
Gambar 15. Distribusi Sentimen Sebelum dan Sesudah *Cleaning*

Gambar di atas mengilustrasikan dampak pembersihan data yang menyebabkan penurunan jumlah tweet di seluruh kategori (negatif, netral, positif), namun sentimen positif tetap mendominasi baik sebelum maupun sesudah proses tersebut. Penurunan minor ini mengindikasikan bahwa proses cleaning efektif mereduksi noise atau data tidak relevan tanpa mengubah proporsi tren sentimen utama secara signifikan.

3.3.2 Kinerja Model Analisis Sentimen

3.3.2.1 Modeling (Screening)

Dalam penelitian ini, dilakukan eksperimen ekstensif dengan menguji kombinasi dari 5 metode ekstraksi fitur yang telah dijabarkan sebelumnya terhadap 25 algoritma *Machine Learning* yang berbeda, menghasilkan total 125 iterasi eksperimen. Berdasarkan hasil eksperimen screening, kinerja untuk setiap metode ekstraksi fitur dan modelnya dirangkum dalam gambar dan tabel berikut:



Gambar 15. Visualisasi Multilayer Network

Gambar menampilkan sepuluh kombinasi algoritma dan fitur terbaik, yang seluruhnya didominasi oleh fitur berbasis Transformer seperti IndoBERT dan IndoTweet. Kombinasi SVM (Polynomial) dengan fitur IndoTweet menjadi yang terbaik dengan skor F1-Macro 0.773, disusul XGBoost + IndoBERT dengan skor 0.770. Pola ini menunjukkan konsistensi keunggulan SVM (baik Polynomial maupun RBF), yang tampak lebih efektif dalam menangani fitur berdimensi tinggi dibandingkan MLP maupun algoritma berbasis pohon.

Fenomena ini mengindikasikan bahwa pada dataset dengan volume terbatas (~2.000 data) namun memiliki variabilitas linguistik tinggi, stabilitas matematis SVM dalam memaksimalkan *margin* keputusan jauh lebih tahan (*robust*) terhadap *noise* dibandingkan arsitektur *Transformer* yang kompleks dan rentan *overfitting*. Dengan kata lain, penelitian ini membuktikan bahwa kompleksitas model tidak selalu berbanding lurus dengan akurasi; keseimbangan antara kekayaan representasi fitur dan kemampuan generalisasi model adalah kunci utama.

Tabel 3. Performa Model Ditinjau dari *F1-Score (Macro)*

Keluarga Model	Model	Metode Feature Extraction				
		Bag of Words	IndoBERT	IndoTweet	TF-IDF	Word2Vec
Liniar Models	Logistic Regression	0.70	0.72	0.67	0.71	0.64
	Ridge Regression	0.71	0.71	0.69	0.73	0.60
	SGD Classifier	0.65	0.75	0.68	0.64	0.50
	Passive Aggressive	0.72	0.73	0.69	0.71	0.45
Suport Vector Machine	Liniar SVC	0.67	0.71	0.66	0.70	0.67
	SVC RBF	0.64	0.76	0.77	0.28	0.56
	SVC Poly	0.30	0.76	0.77	0.28	0.56
	Nu-SVC	0.69	0.73	0.75	0.70	0.45
Naive Bayes	Perceptron	0.73	0.73	0.71	0.72	0.44
	Multinomial NB	0.74	0.68	0.53	0.68	0.46
	Bernoulli	0.72	0.31	0.29	0.72	0.18
	Complement	0.73	0.66	0.52	0.72	0.46
Tree-Based and Ensemble	Gaussian NB	0.64	0.69	0.60	0.63	0.52
	Decission Tree	0.67	0.59	0.61	0.63	0.57
	Random Forest	0.67	0.72	0.72	0.73	0.59
	Extra Trees	0.72	0.74	0.71	0.73	0.58
Advanced Ensemble	AdaBoost	0.64	0.68	0.66	0.62	0.58
	Gradient Boosting	0.70	0.72	0.74	0.70	0.60
	XGBoost	0.72	0.77	0.73	0.69	0.58
	LightGBM	0.70	0.00	0.00	0.72	0.00
Neural Networks	CatBoost	0.71	0.73	0.72	0.70	0.58
	MLP Shallow	0.68	0.75	0.75	0.68	0.61
Distance Based	MLP Deep	0.72	0.73	0.72	0.70	0.61
	KNN	0.43	0.70	0.66	0.41	0.60
	Nearest Centroi	0.61	0.67	0.52	0.66	0.45

3.3.2.2 Analisis Hasil Screening

Temuan krusial yang menentukan arah tahap optimasi selanjutnya:

- Keunggulan Fitur Berbasis Transformer: Metode ekstraksi fitur berbasis Deep Learning (IndoBERT dan IndoTweet) secara konsisten menghasilkan kinerja F1-Score yang lebih tinggi dibandingkan metode tradisional (BoW, TF-IDF) dan Word2Vec. Hal ini terlihat jelas pada Gambar di mana sebaran titik data untuk IndoBERT (tanda tambah merah) dan

- IndoTweet (wajik ungu) mendominasi area di bagian atas grafik (skor tinggi), mengindikasikan representasi vektor kontekstual mampu menangkap makna semantik dengan jauh lebih baik.
2. IndoTweet vs IndoBERT: Fitur IndoTweet memberikan hasil sedikit lebih unggul (0.7735) dibandingkan IndoBERT (0.7700). Hal ini wajar mengingat IndoTweet dilatih secara spesifik pada korpus Twitter bahasa Indonesia, sehingga lebih adaptif terhadap gaya bahasa informal yang dominan dalam dataset RUU KUHAP.
 3. Kinerja Algoritma Klasik vs Ensemble: Meskipun fitur yang digunakan sangat kompleks (dimensi 768 dari Transformer), algoritma klasik seperti Support Vector Machine (SVM) dengan kernel Polinomial mampu mengungguli algoritma ensemble modern seperti XGBoost dalam konteks ini.
 4. Efisiensi Waktu dan Komputasi (Analisis Mendalam):
Analisis pada Gambar diatas memvisualisasikan *trade-off* krusial antara biaya komputasi (waktu pelatihan dalam skala logaritmik) dan efektivitas model (*F1-Macro*). Berdasarkan sebaran data pada scatter plot tersebut, ditemukan pola-pola signifikan:
 - a. Dominasi Fitur Transformer: Secara visual, simbol tanda tambah merah (IndoBERT) dan wajik ungu (IndoTweet) secara konsisten terkonsentrasi di bagian atas grafik (*F1-Score* → 0.70). Hal ini kontras dengan fitur Word2Vec (kotak hijau) yang cenderung tersebar di area bawah, menegaskan bahwa embedding kontekstual jauh lebih efektif daripada representasi statis.
 - b. Identifikasi Sweet Spot: Titik yang ditandai sebagai "BEST: SVM (*Poly*)" menempati posisi paling strategis di kuadran kiri-atas. Model ini mencapai performa puncak dengan waktu pelatihan di kisaran 10^{-1} hingga 10^0 detik.
 - c. Inefisiensi Algoritma Kompleks: Terdapat klaster model di sisi kanan grafik (waktu 10^1 - 10^2 detik) yang memiliki skor F1 setara dengan model di sisi kiri. Karena sumbu X menggunakan skala logaritmik, jarak horizontal ini merepresentasikan perbedaan waktu nyata hingga 100 kali lipat. Artinya, algoritma *Ensemble* (seperti *XGBoost/Random Forest*) memakan sumber daya komputasi jauh lebih besar tanpa memberikan peningkatan akurasi yang sepadan dibandingkan SVM.
- Berdasarkan tahap screening ini, model SVM (*Polynomial*) dengan fitur IndoTweet ditetapkan sebagai kandidat utama untuk dioptimasi lebih lanjut karena menawarkan keseimbangan terbaik antara akurasi dan efisiensi.
- ### 3.2.2.3 Parameter-Efficient Fine-Tuning (PEFT) dengan LoRA
- Sebagai bandingan efisiensi, penelitian ini juga menerapkan metode LoRA (*Low-Rank Adaptation*) pada model IndoBERT. LoRA membekukan (*freeze*) sebagian besar bobot model *pre-trained* dan hanya melatih matriks dekomposisi pangkat rendah (*low-rank matrices*) pada lapisan *attention*.
1. Konfigurasi LoRA: Rank (*r*) = 16, Alpha = 32, Dropout = 0.1.
 2. Efisiensi: Dengan metode ini, jumlah parameter yang dilatih (*trainable params*) berkurang drastis menjadi hanya 592.131 parameter (sekitar 0,47% dari total 125 juta parameter IndoBERT), yang secara signifikan mempercepat waktu komputasi dan mengurangi penggunaan memori GPU.

3.3. Hyperparameter Tuning

3.3.1 Hyperparameter Tuning: Machine Learning (Grid Search CV)

Untuk model *machine learning* dilakukan pada model terbaik pada tahap *screening* dan dilakukan dengan parameter sebagai berikut:

1. *Support Vector Machine* (SVM) - Kernel Polinomial & RBF:
 - a. *C (Regularization)*: [1, 10, 50] — Mengontrol *margin error*; nilai kecil memperluas margin (lebih general), nilai besar mempersempit margin (lebih akurat pada data latih).
 - b. *gamma*: ['scale', 0.1] — Mengatur pengaruh satu sampel data latih.
 - c. *degree* (khusus Poly): [2, 3] — Menguji kompleksitas polinomial kuadratik vs kubik.
2. Linear SVC: C: [0.1, 1, 10].
3. XGBoost (*Gradient Boosting*):
 - a. *learning_rate*: [0.1, 0.3] — Langkah pembaruan bobot *boosting*.
 - b. *n_estimators*: [100, 300] — Jumlah pohon keputusan yang dibangun.
 - c. *max_depth*: [6] — Kedalaman maksimal pohon untuk mengontrol kompleksitas.
4. MLP Classifier (*Neural Network*):
 - a. *alpha*: [0.0001, 0.001].
 - b. *learning_rate_init*: [0.001].

Hasil Tuning Machine Learning

Dari parameter terbaik yang digunakan, diketahui bahwa model terbaik yang dihasilkan dari fine-tuning machine learning adalah SVM (Polynomial) menggunakan feature extraction IndoTweet dengan F1-Macro Score yang naik dari 0.77 Menjadi 0.85

3.3.2 Hyperparameter Tuning: Deep Learning (Iterative Optimization)

Pada model berbasis Transformer (IndoBERT dan IndoTweet), *tuning* dilakukan melalui serangkaian eksperimen iteratif dengan memodifikasi strategi pelatihan (*training arguments*) untuk menangani tantangan spesifik dataset, seperti *overfitting* dan ketidakseimbangan kelas.

Fase 1: Baseline Fine-Tuning

Eksperimen awal menggunakan konfigurasi standar untuk menetapkan garis dasar kinerja.

1. *Warmup Ratio*: 0.1 (10% langkah awal digunakan untuk pemanasan *learning rate*)
2. *Batch Size*: 16 (Train) dan 32 (Eval).
3. *Optimizer*: AdamW dengan *learning rate* 2×10^{-5} .
4. *Scheduler*: *Cosine Decay* dengan *warmup ratio* 0.1 untuk mencegah *gradien explosion* di awal pelatihan.
5. *Epoch*: 3 epoch.

Fase 2: Advanced Tuning (Weighted Loss & Regularization)

Untuk mengatasi stagnasi pada fase 1 dan isu ketidakseimbangan data, diterapkan strategi optimasi lanjutan menggunakan kelas *WeightedTrainer* kustom:

1. *Handling Imbalance (Class Weighting)*: Menghitung bobot kelas secara invers proporsional terhadap frekuensi data. Bobot yang diterapkan adalah: Negatif: 1.10, Netral: 1.00, dan Positif: 0.91. Bobot ini dimasukkan ke dalam fungsi kerugian *CrossEntropyLoss* agar model memberikan perhatian lebih pada kelas minoritas (Negatif).
2. Regularisasi & Stabilitas:
 - a. *Weight Decay*: Dinaikkan menjadi 0.05 untuk penalti kompleksitas yang lebih ketat.
 - b. *Label Smoothing*: Sebesar 0.1 untuk mencegah model menjadi terlalu percaya diri (*overconfident*) pada prediksinya.
 - c. *Early Stopping*: Menghentikan pelatihan jika *F1-Macro* tidak membaik dalam 3 epoch berturut-turut (Patience=3).

d. *Epoch*: Batas maksimum dinaikkan menjadi 25 epoch untuk memberi ruang konvergensi

Fase 3: Parameter-Efficient Tuning (LoRA)

Sebagai alternatif efisiensi, diterapkan *Low-Rank Adaptation* (LoRA) pada IndoBERT dengan konfigurasi: *Rank (r)*: 16, *Alpha*: 32, *Dropout*: 0.1, dan *Learning Rate*: 1×10^{-3} .

Hasil Tuning Deep Learning

Pendekatan Fase 2 (*Advanced Tuning*) pada IndoBERT memberikan stabilitas terbaik dengan validasi akurasi mencapai 81.8% dan F1-Macro yang seimbang antar kelas, sehingga dipilih sebagai representasi terbaik dari kategori *Deep Learning*.

Hasil Akhir Eksperimen Fine-Tuning

Evaluasi kinerja model *Fine-Tuning* dilakukan pada *validation set* dan *test set*. Ringkasan hasil eksperimen disajikan dalam tabel berikut:

Tabel 4. Perbandingan Kinerja Model Fine-Tuning

Model	Metode	Accuracy	F1-Macro	Keterangan
SVM Poly (IndoTweet)	Full Fine-Tuning	85%	0.85	Performa Stabil dengan <i>F1-Score</i> yang cukup seimbang di setiap label
IndoBERT	Full Fine-Tuning	82%	0.82	Performa stabil, sedikit overfitting di epoch akhir.
IndoTweet	Full Fine-Tuning	80%	0.79	Performa baik pada bahasa informal, namun sedikit di bawah IndoBERT pada test set.
IndoBERT	PEFT (LoRA)	78%	0.77	Efisiensi tinggi, performa mendekati full fine-tuning dengan biaya komputasi rendah.

3.3.3 Analisis Hasil Fine-Tuning vs Screening

Meskipun teknik *Fine-Tuning* (terutama IndoBERT Full) menghasilkan F1-Score yang sangat kompetitif (0.82 pada validasi internal), namun ketika diuji pada data tes terpisah, kinerjanya tidak melampaui secara signifikan model terbaik dari tahap *screening* (SVM *Polynomial & Feature Extraction* IndoTweet) dengan hyperparameter tuning yang mendapatkan F1-Score mencapai 0.85.

Temuan ini menunjukkan bahwa untuk dataset dengan ukuran moderat (~2.000 data), pendekatan hibrida (menggunakan *embedding* Transformer sebagai fitur statis untuk algoritma SVM) memberikan keseimbangan terbaik antara performa akurasi dan efisiensi waktu pelatihan dibandingkan melakukan *fine-tuning* mendalam yang memakan sumber daya komputasi besar.

3.4 Analisis Kesalahan

Menggunakan data uji (20% dataset), kesalahan dikategorikan menjadi dua taksonomi utama:

1. Kesalahan Fatal (*Fatal Errors*): Kesalahan prediksi yang berlawanan arah polaritas (Positif ke Negatif). Ini adalah jenis kesalahan yang paling berbahaya karena dapat membalikkan kesimpulan analisis opini publik.
2. Kesalahan Ambiguitas (*Ambiguity Errors*): Kesalahan klasifikasi yang melibatkan kelas Netral (Sentimen ke Netral). Kesalahan ini lebih dapat ditoleransi karena batas antara opini subjektif dan pernyataan fakta seringkali tipis.

3.4.1 Analisis Kesalahan pada Model Machine Learning (SVM Polynomial)

Model terbaik yang terpilih dari tahap *Hyperparameter Tuning* adalah *Support Vector Machine* (SVM) dengan kernel *Polynomial* (Degree=3) dan fitur IndoTweet Embeddings.

Distribusi Kesalahan (*Confusion Matrix*)

Berdasarkan evaluasi pada data uji, model SVM mencatatkan kinerja sebagai berikut:

1. Total Data Uji: 385 data.

2. Total Kesalahan: 56 data (Tingkat Kesalahan: 14,5%).
3. Akurasi: 85%.

Distribusi kesalahan secara spesifik adalah:

1. Kesalahan Fatal: 8 kasus (2% dari total data).
2. Kesalahan Ambiguitas: 48 kasus (12,5% dari total data).

Bedah Kasus: Kesalahan Fatal

Temuan paling menarik dari model SVM adalah ketidaksimetrisan kesalahan fatalnya.

1. Kasus Negatif diprediksi Positif (*False Optimism*): 0 Kasus.

Model SVM menunjukkan kekokohan luar biasa dalam mengenali sentimen negatif. Tidak ada satupun tweet kritik/keluhan yang salah diklasifikasikan sebagai dukungan/positif. Ini sangat krusial untuk pemantauan isu RUU KUHAP agar tidak terjadi *underestimation* terhadap resistensi publik.

2. Kasus Positif diprediksi Negatif (*False Pessimism*): 8 Kasus.

Seluruh kesalahan fatal terjadi pada arah ini. Contoh sampel:

"banyak teriak darurat kitab undang undang hukum acara pidana padahal belum baca satu pasal"

- a. Label Asli: Positif (Mendukung RUU/Mengkritik penolak RUU).
- b. Prediksi: Negatif.
- c. Analisis Linguistik: Model terkecoh oleh kata-kata bermuatan negatif kuat seperti "teriak" dan "darurat". Secara sintaksis, kalimat ini adalah *kritik terhadap pengkritik* (defensif), yang secara pragmatik bermakna dukungan terhadap RUU. SVM gagal menangkap nuansa sarkasme atau kritik defensif ini.

Bedah Kasus: Kesalahan Ambiguitas

Mayoritas kesalahan (48 kasus) terjadi pada area abu-abu antara Netral dan Sentimen.

1. *Contoh*: "benar klaim polisi tangkap orang bukti pidana rancangan undang undang... memang hoaks"
2. *Analisis*: Kalimat yang berisi klarifikasi fakta (*debunking hoax*) sering dilabeli sebagai Positif (dukungan narasi), namun model memprediksinya sebagai Netral karena struktur kalimatnya yang deklaratif dan minim kata sifat emosional.

3.4.2 Analisis Kesalahan pada Model Deep Learning (*IndoBERT & IndoTweet*)

Sebagai pembanding, dilakukan analisis serupa pada model *Deep Learning* hasil *fine-tuning*. Berikut perbandingan tingkat kesalahan antara model *Deep Learning* dan model *SVM* terpilih:

Tabel 5. Distribusi Kesalahan Model Deep Learning vs SVM

Tipe Kesalahan	<i>SVM (Poly)</i>	<i>IndoBERT (Tuned)</i>	<i>IndoTweet (Tuned)</i>
Akurasi Total	85%	82%	80%
Total Kesalahan	56 Kesalahan (14,5%)	70 Kesalahan (18%)	78 Kesalahan (22,2%)
Fatal: Positif Negatif	8 Kesalahan (2%)	14 Kesalahan (3,5%)	15 Kesalahan (3,8%)
<i>Fatal: Negatif Positif</i>	0 Kesalahan (0%)	0 Kesalahan (0%)	0 Kesalahan (0%)
Ambiguitas (Netral)	48 Kesalahan (12,5%)	56 Kesalahan (14,5%)	63 Kesalahan (16,4%)

Analisis Kelemahan Deep Learning

Meskipun menggunakan arsitektur Transformer yang canggih, model *Deep Learning* (*IndoBERT & IndoTweet*) justru menghasilkan jumlah kesalahan fatal yang lebih tinggi (14-15 kasus) dibandingkan SVM (8 kasus).

1. Isu *Over-complexity*: Pada dataset berukuran sedang (± 2.000 data), model *Deep Learning* dengan jutaan parameter cenderung mengalami kesulitan generalisasi (*overfitting* pada noise) dibandingkan SVM yang mencari *hyperplane* optimal dengan prinsip margin maksimal.
2. Contoh Kesalahan Spesifik IndoBERT:
"rancangan undang undang... disahkan allah bakal banyak orang planga plongo bakal bilang salah apa..."
 - a. Label Asli: Positif.
 - b. Prediksi: Negatif.
 - c. Analisis: Model gagal memahami konteks "planga plongo" yang ditujukan kepada pihak oposisi RUU. Kompleksitas kalimat yang panjang dan tidak baku menyulitkan model untuk menavigasi dependensi jarak jauh (*long-term dependency*) dalam kalimat tersebut.

3.4.3 Analisis Kesalahan Prediksi *Machine Learning* dengan *Deep Learning*

Berikut disajikan tiga contoh teks yang diperoleh dari hasil perbandingan prediksi sentimen antar model *machine learning* dan *deep learning*. Contoh-contoh ini dipilih karena menunjukkan adanya perbedaan hasil klasifikasi antara label sentimen sebenarnya (*ground truth*) dan prediksi yang dihasilkan oleh model IndoBERT, IndoTweet, serta Support Vector Machine (SVM). Melalui penyajian contoh ini, dapat terlihat bagaimana setiap model memberikan respons yang berbeda terhadap teks dengan karakteristik bahasa yang beragam, sehingga membantu mengidentifikasi pola kesalahan prediksi yang terjadi.

Tabel 6. Perbandingan Sentimen *Machine Learning* dengan *Deep Learning*

Teks	Sentimen			
	Ground Truth	IndoBERT	IndoTweet	SVM
Damai dikit tiba2 ruu kuhap sah.	<i>negative</i>	<i>positive</i>	<i>positive</i>	<i>negative</i>
wallahi we really finished guys. ruu KUHAP sudah disahkan...	<i>negative</i>	<i>positive</i>	<i>positive</i>	<i>negative</i>
GAK BAHAYA TA?! Lagi rame banget nih pamflet ngawur di sosmed soal RUU KUHAP. Isinya bikin panik padahal % Hoax tentang KUHAP! Kita kudu barengan Lawan Disinformasi dan Hoax biar gak gampang diadu domba. Geser ke bawah Bro! https://t.co/OfagWNBUnc	<i>positive</i>	<i>negative</i>	<i>negative</i>	<i>negative</i>

Analisis kesalahan pada tabel menunjukkan bahwa IndoBERT dan IndoTweet cenderung mengalami over-interpretation terhadap semantik kata, sehingga terkecoh oleh dominasi kata bermakna positif seperti "damai" atau "sah" dalam konteks sarkasme (Baris 1) dan gagal menangkap nuansa pesimistik dari slang bahasa Inggris "finished" yang tertutup oleh kata formal "disahkan" (Baris 2). Kelemahan ini diperparah pada tweet defensif (Baris 3), di mana mekanisme attention model justru terdistraksi oleh banyaknya kata negatif "bising" seperti "hoax" atau "panik" sehingga salah mengklasifikasikannya sebagai sentimen negatif; sebaliknya, SVM mampu memprediksi dengan benar karena pendekatannya yang berbasis pola leksikal sederhana (seperti mendeteksi frasa kunci "Lawan Hoax" atau n-gram tertentu) lebih efektif memilah sinyal utama dari noise tanpa terbiaskan oleh ambiguitas konteks yang rumit.

3.5 Aspect Based Sentiment Analysis (BERTopic)

3.5.1 Aspek Negatif

Berdasarkan hasil bedah aspek negatif, resistensi publik mengerucut pada tiga isu utama. Pertama, kekhawatiran terbesar berpusat pada perluasan wewenang aparat penegak hukum yang dinilai berlebihan dan berpotensi memicu penyalahgunaan kekuasaan (Topik 0). Kedua, publik menyoroti dampak langsung terhadap kebebasan sipil, khususnya ketakutan bahwa kritik

terhadap pemerintah dapat dengan mudah di kriminalisasi/ berujung pidana (Topik 3). Ketiga, terdapat sentimen ketidakpercayaan pada prosedur legislasi yang dianggap terburu-buru dan tidak transparan, di mana publik membandingkan cepatnya pengesahan RUU ini dengan lambatnya RUU lain yang lebih mendesak seperti RUU Perampasan Aset (Topik 1 & 4).

3.5.2 Aspek Netral

Analisis aspek netral didominasi oleh percakapan yang bersifat informatif dan objektif. Mayoritas data (Topik 0 dan 1) berisi penyebaran berita faktual mengenai substansi hukum acara pidana serta pengumuman resmi dari DPR terkait pengesahan undang-undang, tanpa muatan emosi yang kuat. Selain narasi berita, teridentifikasi juga adanya noise atau gangguan data (Topik 2, 3, dan 4) berupa aktivitas spam promosi komersial yang tidak relevan, namun volumenya jauh lebih kecil dibandingkan percakapan substantif mengenai hukum.

3.5.3 Aspek Positif

Analisis sentimen positif didominasi oleh dua narasi utama: dukungan terhadap pembaruan paradigma hukum dan upaya masif meluruskan disinformasi. Pertama, publik mengapresiasi pergeseran menuju keadilan restoratif (*restorative justice*) yang dianggap mampu membatasi kesewenang-wenangan aparat melalui prosedur yang lebih ketat (Topik 0). Kedua, terdapat mobilisasi narasi yang kuat untuk melawan 'hoax' dan kepanikan masyarakat (Topik 1, 2, 3, dan 4), khususnya klarifikasi bahwa isu sensitif seperti penyadapan dan penangkapan tidak dilakukan sembarangan, melainkan diatur ketat melalui undang-undang khusus dan wajib seizin pengadilan.

Discussion

Berdasarkan analisis kesalahan yang komprehensif, dapat disimpulkan beberapa poin kunci:

1. Dominasi SVM: Untuk karakteristik dataset RUU KUHAP ini, model SVM (*Polynomial*) terbukti lebih unggul dan stabil dibandingkan pendekatan *Fine-Tuning Transformer*. SVM mampu meminimalkan kesalahan fatal secara signifikan.
2. Pola "Optimisme Palsu" Nihil: Baik model ML maupun DL menunjukkan performa sempurna (0 kesalahan) dalam memprediksi sentimen Negatif menjadi Positif. Ini menunjukkan fitur-fitur yang diekstraksi (terutama dari *embedding IndoTweet*) sangat kuat dalam merepresentasikan sinyal-sinyal kritik dan penolakan.
3. Tantangan Sarkasme: Kelemahan utama seluruh model terletak pada deteksi sentimen positif yang disampaikan melalui sarkasme atau serangan balik terhadap pihak kontra (*defensive sentiment*). Kata-kata negatif dalam kalimat tersebut mendominasi *attention mechanism* atau bobot fitur, sehingga model salah mengklasifikasikannya sebagai sentimen negatif.

Conclusion

5.1 Kesimpulan

Penelitian ini dilakukan untuk memahami bagaimana masyarakat merespons isu RUU KUHAP di Platform X. Dilakukan dengan dua cara analisis utama, Analisis Jaringan Sosial (SNA) untuk melihat pola interaksi, dan Analisis Sentimen Berbasis Aspek (ABSA) untuk mengetahui sentimen pada topik-topik spesifik.

1. Dinamika Jaringan: Pembahasan publik mengenai RUU KUHAP di Platform X ternyata tidak seperti diskusi biasa, melainkan lebih sering berupa penyebaran informasi cepat dan satu arah (melalui *retweet* dan *hashtag*). Jaringan antar pengguna cenderung terpisah-pisah (terfragmentasi), yang menunjukkan bahwa isu ini lebih cepat menjadi viral daripada dibahas secara mendalam.

2. Kualitas Model Sentimen: Untuk memprediksi sentimen, kami menemukan bahwa model SVM (Support Vector Machine) dengan fitur IndoTweet adalah yang terbaik, mencapai akurasi tinggi dengan F1-Score 0.773. Ini menunjukkan bahwa model sederhana yang dibantu oleh teknologi *embedding* bahasa modern sudah cukup efektif untuk data ini.
3. Sentimen Berdasarkan Topik (ABSA): Analisis menunjukkan bahwa sentimen negatif yang paling kuat muncul pada aspek-aspek kontroversial yang berisi berita bohong atau menyesatkan (misalnya, klaster 'UNDANG_PANIK_UNDANG_UNDANG_HOAX'). Ini membuktikan bahwa reaksi masyarakat sangat dipengaruhi oleh disinformasi yang beredar dalam jaringan.
4. Temuan Utama: Kesimpulannya, sentimen negatif yang kuat terbentuk karena adanya penyebaran berita bohong yang cepat oleh aktor-aktor tertentu di dalam jaringan yang terpisah-pisah di Platform X.

5.2 Saran untuk Penelitian Selanjutnya (*Future Works*)

Berdasarkan hasil penelitian ini, ada beberapa hal yang bisa dikembangkan di masa depan:

1. Penyempurnaan Model Sentimen: Membuat satu model yang bisa langsung mengidentifikasi topik sekaligus sentimen dalam satu kali proses, agar analisis lebih cepat dan efisien.
2. Analisis Jangka Panjang: Melakukan penelitian yang mengamati perubahan opini dari awal RUU diusulkan hingga setelah disahkan, untuk melihat bagaimana dinamika sentimen berubah seiring waktu.
3. Perbandingan Platform: Menguji metode yang sama pada media sosial lain di luar Platform X untuk melihat apakah pola diskusi dan sentimen yang ditemukan memiliki kesamaan atau perbedaan.
4. Analisis Aliran Informasi: Memperdalam analisis SNA dengan melihat seberapa cepat dan jauh disinformasi menyebar di jaringan.

References

- [1] Veltri, G. A., & Atanasova, D. (2017). Climate change on Twitter: Content, media ecology and information sharing behaviour. *Public Understanding of Science*, 26(6), 721–737. <https://doi.org/10.1177/0963662515613702>
- [2] Himelboim, I., Smith, M. A., Rainie, L., Shneiderman, B., & Espina, C. (2017). Classifying Twitter topic-networks using social network analysis. *Social Media + Society*, 3(1), 1–13. <https://doi.org/10.1177/2056305117691545>
- [3] Pontiki, M., et al. (2016). SemEval-2016 Task 5: Aspect-based sentiment analysis. *Proceedings of the 10th International Workshop on Semantic Evaluation*, 19–30. <https://doi.org/10.18653/v1/S16-1002>
- [4] Sumartias, S., Pulubuhu, D. A. T., Sudarmono, & Adi, A. N. (2023). Democracy in the Indonesian digital public sphere: Social network analysis of Twitter users' responses to the issue of nationalism knowledge test at the Corruption Eradication Commission (TWK-KPK). *Jurnal Ilmu Sosial dan Ilmu Politik*. <https://doi.org/10.22146/jsp.70896>
- [5] Setiadi, T. (2023). Analisis jaringan opini publik tentang Pembatasan Sosial Berskala Besar di Twitter. *Jurnal Media dan Komunikasi Indonesia*. <https://doi.org/10.22146/jmki.82650>
- [6] Sejati, P. T., Al Zami, F., Marjuni, A., Indrayani, H., & Puspitarini, I. D. (2024). Aspect-Based Sentiment Analysis for Enhanced Understanding of 'Kemenkeu' Tweets. *Journal of Applied Informatics and Computing*, 8(2), 487–498. <https://doi.org/10.30871/jaic.v8i2.8558>

- [7] Jasim, Y. A., Saeed, M. G., & Raewf, M. B. (2024). *Analyzing Social Media Sentiment: Twitter as a Case Study*. ADCAIJ: Advances in Distributed Computing and Artificial Intelligence Journal. <https://doi.org/10.14201/adcaij.28394>
- [8] Puluhulawa, F. Y., & Rajiyem, R. (2022). *What Do Opinion Leaders Share from the New Normal on Twitter?: A Qualitative Content Analysis*. Jurnal Ilmu Sosial dan Ilmu Politik, 26(2). <https://doi.org/10.22146/jsp.71844>
- [9] Zitri, I., Kurniawan, C., & Rifaid, R. (2024). *Moving Public Opinion by Politicians: Action Study #AyoMoveOn2024 Through Social Media X*. Journal of Governance and Local Politics (JGLP), 7(1). <https://doi.org/10.47650/jglp.v7i1.1608>
- [10] Suharyanto, S., Sarno, R., Fatihah, C., & Faisal, E. (2023). Aspect Based Sentiment Analysis: systematic literature review. *Journal of Applied Intelligent System*, 5(1). <https://doi.org/10.33633/jais.v5i1.3807>
- [11] Pertwi, R. F. (2025). Analysis of the impact of social media on shaping public perception law enforcement in Indonesia. *Public Service and Society Journal*, 1(1), 1–12. <https://doi.org/10.55942/pssj.v5i9.614>
- [12] Durotoye, T. (2024). Online and social media political participation: Differential effects across platforms. *Social Science Computer Review*, 42(5), 1234–1256. <https://doi.org/10.1177/08944393251332640>
- [13] Magdaci, O., & Colleagues. (2022). Modeling the debate dynamics of political communication in social networks. *Expert Systems with Applications*, 201, 117138. <https://doi.org/10.1016/j.eswa.2022>
- [14] Where do parties interact? Issue engagement in press releases, parliamentary questions, and Twitter. (2023). *European Journal of Political Research*, 62(4), 1020–1042. <https://doi.org/10.1111/1475-6765.12729>
- [15] Han, R., & Colleagues. (2025). Aspect-based sentiment evolution and its correlation with review dynamics. *Knowledge-Based Systems*, 304, 112563. <https://doi.org/10.1016/j.dim.2025>
- [16] Aryanti, F. A. D., & Colleagues. (2025). Aspect-based sentiment analysis with LDA and IndoBERT for mental health app reviews. *Journal of Applied Informatics and Computing*, 9(1), 100–115. <https://doi.org/10.30871/jaic.v9i2.8958>
- [17] Wafda, A., Sari, R. F., & Raharjo, A. B. (2025). Aspect-based sentiment analysis on Twitter towards the Merdeka Curriculum using IndoBERT. *Jurnal Teknologi Informasi dan Ilmu Komputer*, 12(1), 45–56. <https://doi.org/10.33480/jitk.v10i3.5692>
- [18] Turangan, A. D. P., & Pratama, B. (2025). Implementation of feature extraction using BERT in aspect-based sentiment analysis. *EECCIS*, 19(1), 12–20. <https://doi.org/10.21776/jeeccis.v19i2.1770>
- [19] Rahayu, D., & Putra, B. (2025). The use of social media as a provocation tool: A case analysis of political conflict in Indonesia. *Journal of Law, Policy and Humanities*, 4(1), 70–86. <https://doi.org/10.38035/jlph.v5i3.1233>
- [20] The role of public opinion in shaping new criminal law. (2023). *ShodhKosh: Journal of Visual and Performing Arts*, 4(2), 90–101. <https://doi.org/10.29121/shodhkosh.v4.i2.2023.3298>
- [21] Sumartias, S., Pulubuhu, D. A. T., Sudarmono, & Adi, A. N. (2023). Democracy in the Indonesian digital public sphere: Social network analysis of Twitter users' responses to the issue of nationalism knowledge test at the Corruption Eradication Commission (TWK-KPK). *Jurnal Ilmu Sosial dan Ilmu Politik*, 27(1), 1–20. <https://doi.org/10.22146/jsp.70896>

- [22] Irawan, D., Sensuse, D. I., Putro, P. A. W., & Prasetyo, A. (2023). Public response to the legalization of the Criminal Code Bill with Twitter data sentiment analysis. *International Journal of Advanced Computer Science and Applications*, 14(2), 282–291.
<https://doi.org/10.14569/IJACSA.2023.0140236>
- [23] Pratama, R., & Lestari, A. (2023). Democracy on social media: The analysis of the new Criminal Code ratification polemic on Twitter. *Kajian Jurnalisme*, 7(1), 45–60. DOI: <https://doi.org/10.24198/jkj.v7i1.46588>.
- [24] Cahyaningrum, N. I., Yoshida Fatima, D. W., Kusuma, W. A., Ramadhani, S. A., Destanto, M. R., & Nooraeni, R. (2020). Analysis of user sentiment of Twitter to Draft KUHP. *Jurnal Matematika, Statistika dan Komputasi*, 16(3), 273–286.
<https://doi.org/10.20956/jmsk.v16i3.8239>
- [25] Hua, Y. C., Denny, P., Wicker, J., & Taskova, K. (2024). A systematic review of aspect-based sentiment analysis: Domains, methods, and trends. *Artificial Intelligence Review*, 57, Article 296. <https://doi.org/10.1007/s10462-024-10906-z>
- [26] Lakhani, A., Upadhyay, V., & Fiaidhi, J. (2022). Aspect-based sentiment analysis—Twitter. *TechRxiv*. <https://doi.org/10.36227/techrxiv.21699203.v1>
- [27] Luceri, L., Deb, A., Badawy, A., & Ferrara, E. (2019). Red bots do it better: Comparative analysis of social bot partisan behavior. *arXiv*. <https://arxiv.org/abs/1902.02765>
- [28] Purwitasari, D., Purnama Putra, C. B., & Raharjo, A. B. (2023). A stance dataset with aspect-based sentiment information from Indonesian COVID-19 vaccination-related tweets. *Data in Brief*, 47, 108951. <https://doi.org/10.1016/j.dib.2023.108951>
- [29] Radicioni, T., Saracco, F., Pavan, E., & Squartini, T. (2020). Analysing Twitter semantic networks: The case of 2018 Italian elections. *arXiv*. <https://arxiv.org/abs/2009.02960>
- [30] Tanoto, K. (2024). Investigation of challenges in aspect-based sentiment analysis enhanced using softmax function on Twitter during the 2024 Indonesian presidential election. *Procedia Computer Science*. <https://doi.org/10.1016/j.procs.2024.01.123>

Lampiran

Sumber Data (Code Scraping) :

<https://colab.research.google.com/drive/1hsZehvW8pVL8h21Kw1y6HiII94E2gV3S?usp=sharing>

Code :

<https://drive.google.com/drive/folders/1gPwo4YEKnSekFbVOsHVyZloTZhuyXkpa?usp=sharing>